競争的評価に基づく HVAC 最適化のためのベンチマークフレームワーク：第二回電脳建築最適化世界選手権からの知見

A Benchmarking Framework for HVAC Optimization via Competitive Evaluation: Insights from the 2nd WCCBO

Contents

1. Introduction 2
2. Methodology for Quantitative Evaluation of HVAC Optimization 3
   2.1 Emulator Requirements 3
   2.2 Championship Rule Design 3
   2.3 Approach for Data Analysis 3
3. Results and Application of Evaluation Framework 4
   3.1 Overview of VRF System Emulator 4
   3.2 Rules of the championship 4
   3.3 Implementation and Results of Championship 6
   3.4 Data Analysis and Formulation of Evaluation Metrics 6
      1) Distribution of final scores 6
      2) Control methods adopted by players 8
      3) Overview of Optimization Methods Used by Winning Teams 8
      4) Derivation of optimization method evaluation formula 8
   3.5 Verification with Reinforcement Learning 10
4. Discussion 14
   4.1 Avoiding Overfitting 14
   4.2 Integrating Emulator with Real Buildings 15
5. Conclusion 18

1. Introduction

建設部門のエネルギー消費は非常に大きく、IEA の報告書（IEA 2023）によれば、2022 年時点で世界の CO_2 排出量の 33%程度を占めている。同報告書によればその内の 79%（33%の内の 26%）は運用段階に発生しており、建設方法だけではなく、建物を運用する方法を改善することは世界のエネルギー効率に大きな影響を持っている。

このため、建物の設備を最適化する技術に関しては昔から多くの研究があり、快適性、省エネルギー性、室内空気質など、複数の評価関数を持つ多目的最適化問題（Multi-objective optimization）として認識されている(Mindeel 2024)。特に近年では、機械学習の技術が大きく進展したことを背景に研究が増えており、数百もの文献にもとづいたレビュー研究がいくつも報告されている(Xin 2024; Zhou 2023; Ala'raj 2022)。Zhou (2023) と Ala'raj (2022)のレビューでは、設備の最適化に関わる今後の課題がいくつか提示されており、両者がともに指摘する点は、最適化手法自体の評価の不足である。すなわち、数ある最適化手法を比較して、どのような場面においてどのような最適化手法が有効であるのかを明らかにすることが future research direction とされている。

しかし、最適化手法を公平に比較することは簡単ではない。設備システムはそれぞれに異なるため、複数の異なるケーススタディの結果を持ち寄っても、いずれが優秀な手法なのかはすぐには判断できない。この問題を解決するための最も単純な方法は、評価対象以外の最適化手法を同じケースに適用することで性能を比較するという方法であり、こうした報告は多い（Ding et al. 2023; Huchuk et al. 2021; Sun et al. 2024）。しかし、この方法では依然として、様々な最適化手法が示す性能分布の中で評価対象の性能の水準を知ることはできない。

本論文では、この課題の解決に貢献するために、設備の様々な最適化手法を公平に比較して分布の中で性能を評価する方法を提案する。具体的には、以下の通りである。まず、設備システムのシミュレーションモデルを高いリアリティで作り、このモデルを多数の者に仮想的に運用してもらう。モデルが出力したエネルギー消費と不満足率を比較することで相対的に優れた運用を決め、順位付ける。この順位を仮想運用者たちに開示することで、さらに高い評価値が得られるように運用の改善を競わせる。こうして得られた多数の運用結果を分布として捉えて定式化する。この式を使えば、ある特定の評価したい最適化手法が、エネルギー性能と快適性という観点において、全体の分布の中ではどの程度の水準なのかを定量的に示すことができるようになる。

こうしたリアリティの高いシミュレーションモデルはエミュレータと呼ばれており、Lebrun (1993), IEA (1997;1999), Vaezi-Nejad (1991), Bushby (2001; 2010)など、多数の開発報告がある。近年では、単独ではなく、標準化された複数のエミュレータ（テストケース）上で、様々な制御戦略を大規模に比較・評価するためのベンチマーキングフレームワークである *Building Optimization Testing* (BOPTEST)も開発されている（Blum et al. 2021）。そこで本研究では以下に示す 2 点の新規性によって、これらの既往研究の成果を補完することを試みた。第一に、本研究は最適化手法の選手権という、エミュレータの具体的な応用方法と実践例を提示するものであり、性能評価に競争原理を応用しようとしている。これによって多数の運用結果にもとづく分布として最適化手法のベースラインを捉えることができるようになる。第二に、既存のエミュレータとは異なり、VRF（Variable Refrigerant Flow）システムをエミュレーションの対象としている。VRF システムは近年、施工数が非常に増加しており（Aynur 2010; Lin et al. 2015; Zhang et al. 2019）、棟数でみれば日本の事務所の約 9 割を占める (NILIM 2025)。従って VRF システムの運用の良否を定量的

に評価することは社会的に非常に意義があろう。また、本論文の第 3 章では、本研究で開発した性能評価システムの具体的な適用例として、強化学習による最適化手法を評価した結果も報告する。本研究で開発する手法が AI による最適化手法の評価にも応用できれば、VRF のように極めて数の多い空調システムの運用改善に費やされる労働を大きく削減する可能性が生まれるだろう。

2. Methodology for Quantitative Evaluation of HVAC Optimization

本研究では、以下の手順に従って、最適化手法評価ツールを開発する。

1）VRF を導入した建物の不満足率とエネルギー消費を計算できるエミュレータを開発する
2）開発したエミュレータを使って建物の最適化を競う選手権のルールを作成する
3）作成したルールに従って選手権を実施してエミュレータの出力データを収集する
4）収集したデータを分析して最適化手法評価式を導出する
5）導出した評価式を強化学習による最適化手法に適用することでツールの有効性を検証する

上記のいくつかの手順について注意点を以下に整理する。

2.1 Emulator Requirements

第一に、最適化手法を評価することが目的であるため、制御の自由度を高める。伝統的な多くのエネルギーシミュレータのように、予めシミュレータに組み込まれたいくつかの制御システムの中から 1 つを選択するような仕様とはしない。一方で、プラグマティックな見地からは、現実の VRF システムが受け取れないような、自由過ぎる制御内容としては価値がない。従って、両者のバランスをとり、現実のシステムへの適用可能性を保証としつつ、ユーザーによる新たな制御システムを受け取り、評価できるようにする。

第二に、単一指標とはせず、複数指標による最適化問題とする。Introduction で述べたように設備の最適化が困難であることの 1 つの理由は、評価すべき指標が複数あり、それらがトレードオフの関係を持つことにある。本研究では主要な指標であるエネルギー性能と快適性に注目する。従って、エミュレータはこれらの両性能のトレードオフ関係を正しく評価し、その性能を定量的に出力できるようにする。

2.2 Championship Rule Design

多くのデータを収集することが目的であるため、競争原理を十分に働かせることで、参加者に繰り返し運用を試させる必要がある。このために、上位に入賞することのインセンティヴを用意するとともに、評価指標を明確に定義することで順位を明らかにする。この評価指標は、快適性とエネルギー性能の両方を十分に反映したバランスの良い方法で計算する。また、現実の VRF システムへの適用という観点からは、ある特定の条件において有効なだけではなく、未知の条件に対しても性能低下が少ない、堅牢な最適化手法でなければならない。言い換えれば、過学習による最適化を高く評価するようなルールとはしない。

2.3 Approach for Data Analysis

最適化手法評価式は、収集した多数のデータから導出する。従って、評価式の特性や限界を知るために、収集されたデータがどのような傾向を持つのか、十分に分析する。また、選手権参加者へのアンケートやヒアリングなども実施することで、これらのデータが生み出された前提条件を明らかにする。

3. Results and Application of Evaluation Framework

2 章で示した手順に従って研究を実施した結果を記す。ただし「1）エミュレータの開発」と「2）選手権ルールの作成」については既報（Togashi et. al 2024）で詳細に報告したため、本報では 3）以降の理解に必要となる最小限の解説に留めた。

3.1 Overview of VRF System Emulator

7 階建の事務所ビルの 1 フロア、床面積 1,000 m^2 程度の事務室をモデル化の対象とした。事務室には 100 人程度の執務者がおり、その occupant behavior もモデル化した。事務室は 18 のゾーンに分かれ、それぞれを VRF システムの室内機で空調する。各ゾーンには換気のための全熱交換器ユニットも導入されている。

現実の VRF システムへの適用可能性を高めるために、制御できる項目は、主要な VRF 製造者の技術資料を参考に決定した。自由な制御アルゴリズムを開発して試すことができるように、これらの制御項目は BACnet 通信でエミュレータの外部から操作できるようにした。

より多くの運用結果を得るためには、エミュレータの計算時間を短縮すべきである。このため、一回の計算期間は 1 年間とはせず、夏季の 1 週間または冬の 1 週間とした。1 週間分の計算を終えるとエミュレータは積算エネルギー消費量 E [GJ]と執務者の平均不満足者率 DR [-]を出力する。

過学習による最適化を防止するための仕組みとして、執務者の行動と気象条件を確率的要素としてモデル化した。これらの確率的要素は乱数によって表現したため、計算のたびに異なる値となり、過学習による最適化手法は通用しなくなる。ただし、これらの乱数シードは値を固定し、確率的要素を確定的に振る舞わせることもできるようにした。

3.2 Rules of the championship

選手は、BACnet 通信を使って、エミュレータ内部の建物の熱環境、執務者行動、空調システムに関わる情報を受信することができる。同様に、空調システムの様々な設定値を送信して変更することもできる。BACnet 通信のプログラムを開発できない参加者のために、あらかじめ表計算ソフトウェアのファイルに書き込んだ空調スケジュールに従ってエミュレータを操作できる補助プログラムも提供した。

選手は、エミュレータが出力したエネルギー消費量 E と執務者たちの平均不満足者率 DR を記録したファイルを、サーバーにアップロードすることで成績を登録する。選手たちの競争を促すため、新たな成績が登録されると、サーバーは全成績を再計算して順位を更新して公開する。成績の計算方法は以下の通りである。

まず、アップロードされたすべてのエネルギー消費と平均不満足者率のデータが読み込まれ、外れ値（5%）が除かれた後に Box-Cox 変換され、さらに標準正規分布 $N(0,1)$に従う変数として正規化される。累積分布関数を使うことでこれらのデータが 0.0~1.0 の値を持つパーセンタイル値に変換される。この手順に従ってパーセンタイル値に変換されたエネルギー消費量を P_E [-]、平均不満足者率を P_{DR} [-]とする。従って、例えば P_E = 0.9 であれば、それはエネルギー性能が分布の上では上位 10%に含まれることを意味する。

P_E と P_{DR} を統合するため、次式で表される ECI (Energy efficiency and Comfort Index)という指標を定義した。

$$ECI_s = \sqrt{P_{E,s} \cdot P_{DR,s}} \quad \text{Eq. 1}$$

$$ECI_w = \sqrt{P_{E,w} \cdot P_{DR,w}} \quad \text{Eq. 2}$$

ここで、添字の s と w はそれぞれ夏季と冬季を意味する。式から明らかなように ECI も 0.0~1.0 の範囲を持つ。

さらに次式で夏季と冬季の成績を統合して年間の総合成績である ECI_a [-]を定義した。

$$ECI_a = \sqrt{ECI_s \cdot ECI_w} \quad \text{Eq. 3}$$

この他に、年間のエネルギー性能と快適性を評価するための指標として $P_{E,a}$ [-]と $P_{DR,a}$ [-]を次式で定義した。

$$P_{E,a} = \sqrt{P_{E,s} \cdot P_{E,w}} \quad \text{Eq. 4}$$

$$P_{DR,a} = \sqrt{P_{DR,s} \cdot P_{DR,w}} \quad \text{Eq. 5}$$

計算結果のファイルがアップロードできる回数は制限されておらず、何度でも登録して良い。エミュレータはデフォルトでは実時間に比べて 600 倍速で計算が進められるため、20 分ほどの時間をかければ 1 回（つまり 1 週間）の計算ができる。この加速度は選手が用意した PC の性能の制限の中で自由に設定できる。従って、計算効率の良い、速い最適化アルゴリズムを使えば試行できる回数が増え、その分だけ有利になる。

気象条件のように現実には不確実に振る舞う現象への堅牢性も制御戦略の評価では重要である。例えば BOPTEST では近年のバージョンでこのような機能拡張をしている（Zheng et al. 2025）。我々が開発したエミュレータでも気象条件と執務者行動に乱数を組み込んだ。一方で、制御戦略を競争するという場面では、偶然の乱数値によって成績が入れ替わってしまっては不適切である。このため、公平性の確保を目的に、共通の乱数シードを使って気象条件や執務者行動を計算することにした。この乱数シードの値は 2024 年 10 月 29 日に配布された。計算ファイルのアップロードの期限は 11 月 1 日としたため、選手には計算期間として 4 日間（Evaluation period と言う）が与えられた。ただし、エミュレータは 10 月 1 日からダウンロードでき、計算結果もアップロードできるようにした。つまり、選手は最終成績計算用の未知の乱数シードが配られるまで、自分で適当に設定したシードを使い、様々な条件で最適化を試すことができた。この期間を Preparation period と呼ぶ。最終成績は、Preparation period と Evaluation period の両方を含む全期間にアップロードされたすべてのファイルを使って求められた分布にもとづいて計算された。

最終成績評価の期間を上記のように短くしたのは、過学習になるまで最適化モデルを鍛える時間的猶予を与えないことが目的だった。つまり、10 月 1 日から 29 日までの間に様々な乱数で汎化性の高い最適化モデルを鍛え、最後の 4 日間でその性能を試験するという意図だった。ただし、選手権参加者の成績登録回数を見ると、この計画は成功せず、過学習モデルを排除しきれなかったと想像できる。これについては後述する。

競技終了時点において総合成績である ECI_a が最も高い選手が選手権者である。また、第 2 位から 5 位までの選手を入賞者として表彰対象とした。この他に快適性と省エネルギー性のそれぞれを、ほぼ独立に評価する部門賞を設け、$P_{DR,a}$ と $P_{E,a}$ が最も高い選手も表彰対象とした。参加者のインセンティヴを高めるため、表彰者には副賞として賞金を与えることにした。

参加者の不正行為を防止するために技術面と制度面からの措置を講じた。技術的な方法としては、エミュレータの出力ファイルを署名によって暗号化し、その署名が提出サーバーで検証されるようにした。しかし、エミュレータは参加者のローカル PC 上で実行されるため、リバースエンジニアリングなどの高度な改ざん行為を防ぐことはできない。そこで、賞金を受領するための条件として最適化手法を公表す

ることを義務付けた。これにより、説明がつかない好成績を提出することが抑制され、制度面から不正行為を防止することができる。しかし、完全な不正防止のためにはエミュレータを参加者に配布しない評価システムが不可欠だろう。このようなサーバーサイドでの評価フレームワークについては第 4.1 節で議論する。

3.3 Implementation and Results of Championship

選手権には、個人あるいは複数人のいずれでも参加可能とした。このため、以降は「選手」ではなく「チーム」と呼ぶことにする。選手権に参加したチーム数は全部で 62（内、1 チームは途中で辞退）である。チームの属性の内訳は、大学が 33、建築設計が 2、建築施工が 11、機械製造が 8、情報通信・制御システムが 4、不明が 4 だった。

選手権の期間を通じて、計算結果がサーバーに登録された回数は全部で 2407 回だった。Fig. 1 にサーバーに登録された回数の推移を日付別に示す。登録回数は Evaluation period に入ってから不連続に大きくなったため、値を第 2 軸で表している点に注意されたい。

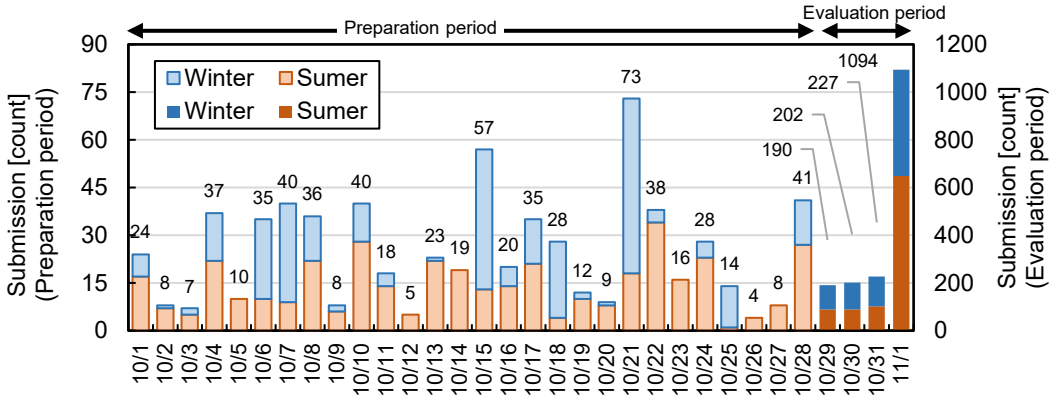


Fig. 1 Number of submissions over time. Due to a sharp increase in the final four days (October 29 to November 1), a secondary Y-axis is used for that period to improve readability.

Preparation period（10 月 1 日から 10 月 28 日）の間には、全部で 693 回（夏季：397 回、冬季：296 回）の成績が登録された。Evaluation period（10 月 29 日から 11 月 1 日）の間には、全部で 1714 回（夏季：929 回、冬季：785 回）の成績が登録された。つまり、全体の約 70%の計算結果は最後の 4 日間に集中して登録され、この間に順位は次々と入れ替わった。評価指標を設けることで設備の運用改善という行為に対して競争原理が導入されたということであり、我々の狙いの一部は実現できたと言える。一方で、最終の短期間に繰り返し成績が登録されたという事実は、最後に配布された乱数シードに対して過学習ができてしまったという可能性を強く示唆する。この問題の解決策については最後に議論する。

3.4 Data Analysis and Formulation of Evaluation Metrics

1) Distribution of final scores

最終成績計算のために用意された乱数シードを使って計算され、Evaluation period に登録されたデータを使って季節別に散布図を描くと Fig. 2 と Fig. 3 が得られる。

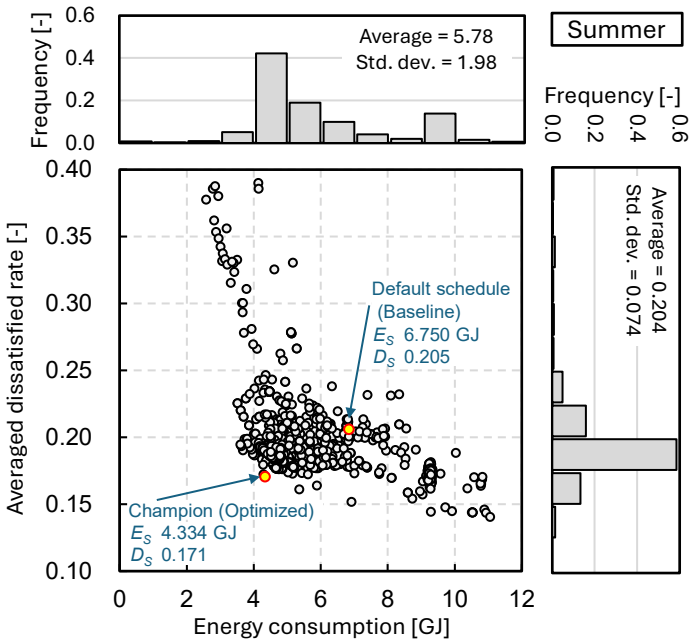


Fig. 2 Distribution of the simulation results for summer

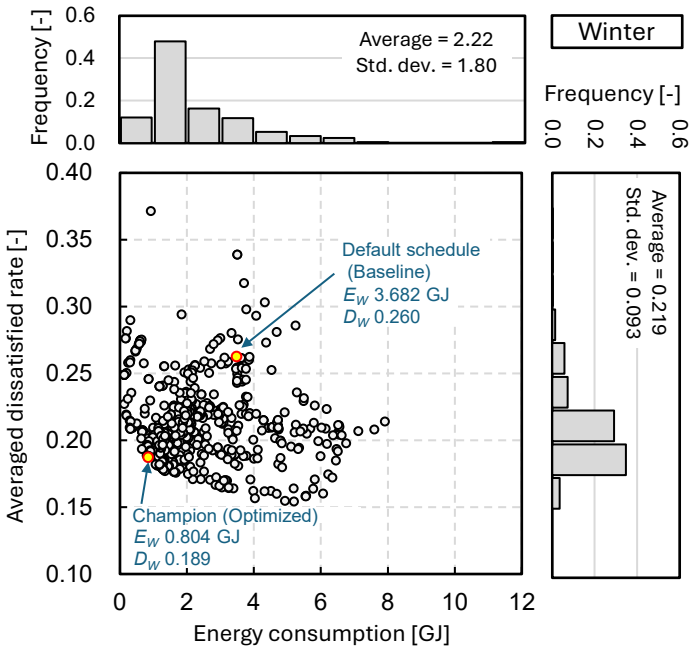


Fig. 3 Distribution of the simulation results for winter

横軸にエネルギー消費、縦軸に不満足者率をとると、季節に関わらず、散布図は左上から右下に向かってプロットされる。エネルギー消費の削減と快適性の向上にはトレードオフの関係があるためである。

乱数シードは共通のため、外気条件と執務者行動は完全に同じである。従って、それぞれの計算結果が異なる値をとり、プロットが散らばる理由は、空調システムの運用方法が異なることが原因である。別の言い方をすると、ハードウェアを改修しなくても、空調設備システムの運用方法を変更するだけで、この

ばらつきに相当するだけ、エネルギー消費と快適性を変えることができるということである。従って、このデータの散らばりは、設備の運用最適化という行為の重要性を表しているとも言える。

2) Control methods adopted by players

BACnet 通信を使えば、エミュレータの現在の状態値に応じてリアルタイムで制御内容を変更できる。制御が予め固定されず、エミュレータとの相互作用によって変化し続けるため、これを「動的制御（Dynamic control）」と呼ぶことにする。しかし、BACnet 通信プログラムを書くことは簡単ではない。そこで、予めスプレッドシートに書き込んだ制御スケジュールに従って、BACnet 通信を代行してくれるプログラムを用意してエミュレータにバンドルした。エミュレータの状態に関係なく制御内容は固定されるため、固定的制御（Static control）と呼ぶことにする。

動的制御は BACnet 通信プログラムの開発が必要になるため、難易度は高い。2018 年に開催された 1st WCCBO でも同じ方式を採用したが、参加者の中で BACnet 通信プログラムを書いたものはわずかに 1 チームだけであった。しかし、動的制御は固定的制御に比べると細やかな制御ができ、機械学習を使った先進的制御も試すことができるという発展性がある。そこで、動的制御と固定的制御のいずれを使ったのかについて、本選手権の終了後に参加者たちにアンケートを取った。

回答者数は 19 で、全体の 30%程度だった。固定的制御のみを使ったと回答した者は 30%程度で、残りの 70%は動的制御のみ、または両者を使ったと回答した。回答したチームは成績が比較的上位だと推測できるため、やや動的制御が大きめになるというバイアスが予想されるが、それでも 1st WCCBO とは全く異なる結果といえる。その理由としては以下の 2 点を挙げることができよう。1 つは、機械学習に関わる技術の急速な進展により、このような動的制御の重要性が理解され始めたことである。もう 1 つは、そもそも 1st WCCBO に比べると本選手権のシステムが単純で制御項目も少なく、制御プログラムが書きやすかった点である。

3) Overview of Optimization Methods Used by Winning Teams

上位に入賞した 5 チームに対して採用した最適化手法の概要をヒアリングした。5 チームの内、4 チームは static control ではなく、Python による dynamic feedback control を作成した。特に上位の 3 チームは執務者の個人個人の熱的嗜好までを制御に反映した点が特徴である。また、いくつかのチームは強化学習などの AI 技術の採用を試みたが、いずれも最終的には断念した。制御項目が多すぎること、データ数を揃えるための時間が不足すること、エミュレータの加速制御が不安定なこと、などが原因だった。従って、本研究で得られた性能分布は、機械学習による最適化は含まない、伝統的なフィードバックによる動的制御に基づく最適化手法の性能分布といえる。また、今後の 1 つの課題は、この性能分布の最高成績を超えるような運用が、機械学習によって実現できるか否かである。後述するように、単純な強化学習では好成績は得られないと予想できるが、もしも本選手権の最高成績を更新できるような機械学習の手法が次々と現れるのであれば、改めてそれらの手法を使った選手権を開催し、分布を更新すべきだろう。

なお、入賞者には副賞を受賞するための要件として、学会大会や論文誌などで自身の最適化手法を発表することを課したため、それぞれの最適化手法の詳細については今後、何らかの方法で情報が公開される予定である。

4) Derivation of optimization method evaluation formula

選手権終了時点におけるすべての運用データを使うことで以下の統計パラメータを推定した。

Table 1 Parameters that describe the distribution of the operational results data

	Summer		Winter	
	Energy	Dissatisfaction	Energy	Dissatisfaction
The parameter λ for the Box-Cox transformation	0.8678	-0.4356	0.3899	-1.3428
The mean μ of the Box-Cox transformed data	3.9653	-2.4076	0.8598	-5.4246
The standard deviation σ of the Box-Cox transformed data	1.5129	0.3343	0.8777	1.0083

これらのパラメータを次式に代入すれば、快適性とエネルギー性能のそれぞれをパーセンタイル値として評価できる。

$$P_E = 1 - \Phi\left(\frac{BC(E) - \mu_{BC,E}}{\sigma_{BC,E}}\right) \quad \text{Eq. 6}$$

$$P_{DR} = 1 - \Phi\left(\frac{BC(DR) - \mu_{BC,DR}}{\sigma_{BC,DR}}\right) \quad \text{Eq. 7}$$

ここで、$BC(\cdot)$は Box-Cox 変換関数、$\Phi(\cdot)$は標準正規分布の累積分布関数である。エネルギー消費 E と平均不満足者率 DR には、評価対象である最適化手法を使ってエミュレータを運用した結果を代入する。

また、上式を使って計算された $P_{E,s}$、$P_{DR,s}$、$P_{E,w}$、$P_{DR,w}$ を Eq. 1~Eq. 3 に代入して ECI_a を求めれば、快適性とエネルギー性能を統合した年間の性能を計算できる。ECI_a は 0.0~1.0 の範囲の値を取るが、定義から明らかなように P_E や P_{DR} とは異なり、パーセンタイル値ではない。そこで、以下に説明するように、選手権参加者の成績をもとにパーセンタイル値に換算するための式を作成した。

まず、次式で順位 n_{rank} をパーセンタイル値 P_{ECI} [-]に変換した。

$$P_{ECI} = \frac{N_{Rank} - n_{Rank} + 0.5}{N_{Rank}} \quad \text{Eq. 8}$$

ここで N_{Rank} は夏季と冬季とで有効な成績を提出できたチームの数で 27 である。$P_{DR,s}$、$P_{DR,w}$、$P_{E,s}$、$P_{E,w}$、の cut-off score を 0.2 としており、これをクリアできたものが「有効な成績」とされる。

P_{ECI} と ECI_a との関係を散布図で表した結果を Fig. 4 に示す。

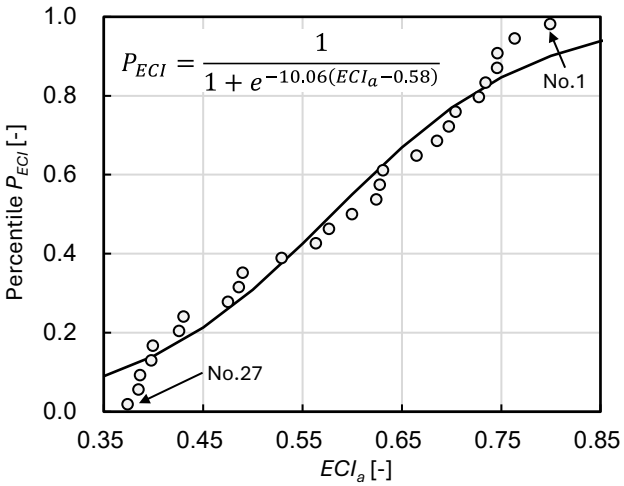


Fig. 4 Relation between ECI_a and percentile

両者の関係をシグモイド関数で近似すると次式となる。

$$P_{ECI} = \frac{1}{1+e^{-10.06(ECI_a-0.58)}} \qquad \text{Eq. 9}$$

先に計算した ECI_a を Eq. 9 に代入すれば、評価対象の最適化手法の性能をパーセンタイル値（P_{ECI} [-]）で評価することができる。なお、Fig. 4 によれば ECI_a と P_{ECI} の関係はほぼ線形に見える。Eq. 9 であえてシグモイド関数で近似した狙いは、ECI_a が 0~1 の範囲において、P_{ECI} の値が漸増し、かつ $0 \leq P_{ECI} \leq 1$ となることを保証することにある。これによって、今後、最適化手法が改良されて本選手権での実績値よりも大きい値を持つ ECI_a が得られた場合にも、それらの優劣を数値で明確に順位付けできる。

3.5 Verification with Reinforcement Learning

成績が上位であったチームのいくつかは機械学習を使った最適化に挑戦したが、最終的にはその手法で最高の成績を得られたものはいなかった。しかし、導入で説明したように、本研究で開発したツールの一つの目的は、現在、非常な勢いで研究報告が増えている機械学習を応用した最適化手法を相互に比較できるようにすることにある。従って、本報で構築したツールを使ってこのような最適化手法が評価できるという点について検証する必要があろう。

以下では機械学習の内、特に強化学習を最適化に応用する場合について述べる。本研究では、強化学習を現実の建物に応用するための枠組みとして Fig. 5 を想定する。一般に強化学習には環境（Environment）とエージェント（Agenet）という 2 つの要素が登場する。Agent が行動（Action）によって Environment に働きかけ、Environment の内部の状態（State）はこの Action によって変化する。エージェントはその変化の結果を観察（Observation）し、その結果に応じて報酬（Reward）を受け取る。この相互のやり取りの中で、優れた Action を学んでいく。これが、図の点線で表した範囲である。

HVAC の最適化という応用においては、Action は各種のコントローラの操作にあたり、Observation は室内の温熱環境やエネルギー消費の状態のモニタリングに相当する。このため、Environment はその裏に Building Emulator を持つことで、Agent から受信した Action を HVAC の操作信号として Emulator に伝え、Emulator が計算した各種の State を Agent に伝達する。

これらの情報の送受信には BACnet protocol が使われることが重要である。何故ならば、開発した最適

化エンジンを接続する相手をエミュレータではなく現実の建物に変えれば、鍛えた最適化エンジンをそのまま使うことができるからである。図の中心の黒い矢印はこれを意味している。本研究で提案したエミュレータで BACnet による通信方式に強くこだわった 1 つの理由はこれが理由である。

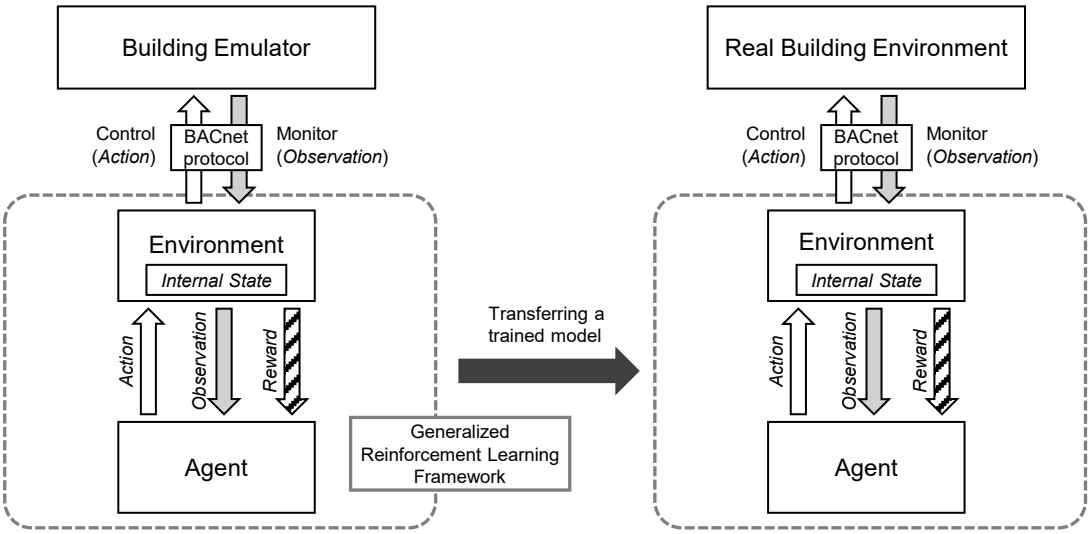


Fig. 5 Generalized reinforcement learning framework for building control

Agent、Environment、エミュレータの具体的なインタラクションフローを Fig. 6 に示す。

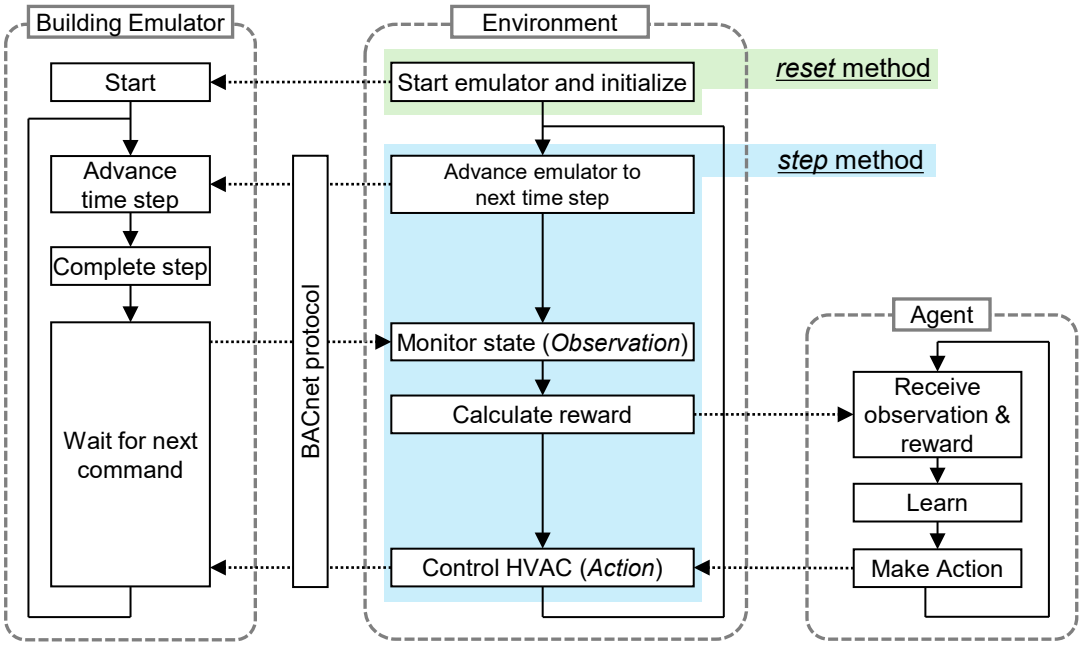


Fig. 6 Process flow of interactions among the reinforcement learning agent, environment, and building emulator using the BACnet communication protocol.

強化学習の各種ライブラリでは API として、エピソードを開始するための reset と、エピソード内で次のタイムステップへと進行するための step というメソッドが提供されていることが一般的である。本図

もこれに対応している。reset メソッドによってエミュレータが起動し、step メソッドによってエミュレータのタイムステップを進める。ここまでの処理はエミュレータ特有の処理だが、これ以降の処理は現実の建物とエミュレータで共通である。具体的には、Environment は BACnet protocol を使うことで建物（あるいはエミュレータ）の内部にある各種の State を取得し、これにもとづいて Reward を計算して Agent に伝達する。Agent は State と Reward にもとづいて次のタイムステップの Action を決定する。この繰り返しの中で優れた Action が探索され、HVAC は最適化される。

上記の枠組みに従い、HVAC の最適化という目的のため、エミュレータを使った強化学習を試行した。ただし、以下の例示は、強化学習による最適化手法を、本研究で提案する手法によって評価できるか否かを検証することが目的であり、最適化手法の性能自体を議論することが目的ではないことに注意されたい。

エージェントの鍛錬には「Stable-Baselines3 (v.2.4.1)」、環境の構築に関しては「Gymnasium (v.1.0.0)」を使った。エミュレータで操作可能な制御項目はすべて選択可能な行動に割り当てた。行動一覧を Table 2 に示す。いずれも離散値である。

Table 2 List of Control Actions

No.	Action	Description
1	VRF On/off state	0:Off, 1:On
2	VRF Operating mode	0:Heating mode, 1:Cooling mode, 2:Fan-only mode
3	VRF Evaporating temperature SP	3~13°C (1°C step)
4	VRF Condensing temperature SP	40~50°C (1°C step)
5	VRF Zone temperature SP	22.0~37.0°C (0.2°C step)
6	VRF Fan speed	0:Low, 1:Middle, 2:High
7	VRF Fan direction	0: Horizontal (0°), 1: 22.5°, 2: 45°, 3: 67.5°, 4: Vertical (90°)
8	VRF Remote control permission	0:Disabled, 1:Enabled
9	Ventilation unit on/off state	0:Off, 1:On
10	Ventilation unit bypass control	0:Disabled, 1:Enabled
11	Ventilation unit fan speed	0:Low, 1:Middle, 2:High

観測できる State は、曜日、日時、外気温湿度、各ゾーンの温度、各ゾーンの執務者数とし、すべて連続量とした。報酬は各タイムステップの不満足者数 N_{DR} [人]と HVAC のエネルギー消費 E を次式に示すように重み付けして計算した。

$$reward = -(N_{DR} + 1250E) \quad \text{Eq. 10}$$

学習の方法は Proximal Policy Optimization (PPO)を使った。ニューラルネットワークの構造は Multi-Layer Perceptron とし、中間層は 4 層、その素子数は 512、256、128、64、活性化関数は ReLU を使った。

Episode の経過に伴う Reward の変化を Fig. 6 に示す。Reward は増加し、学習が進展していることが確認できる。

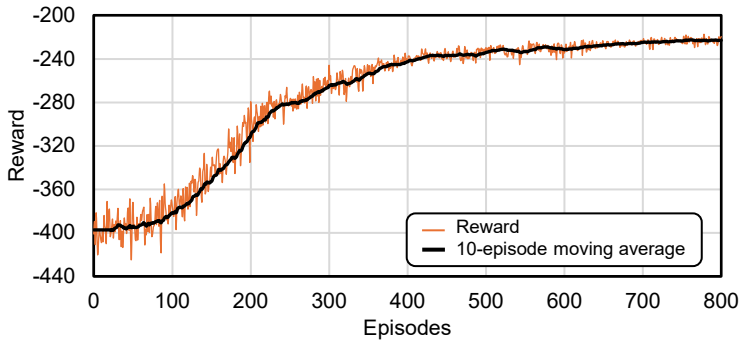


Fig. 7 Learning curve showing the changes in rewards over episodes

代表日における VRF のエネルギー消費を Episode 数別に Fig. 8 に示す。初期状態ではランダムに起動していた VRF が、学習の進展に伴って営業時間帯に優先的に起動するように変わっている。

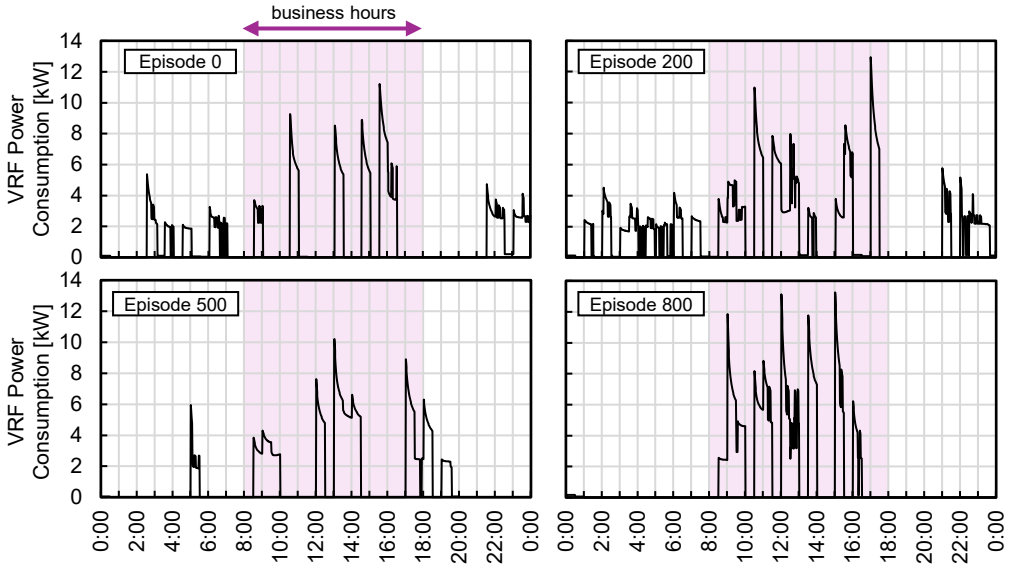


Fig. 8 Changes in VRF power consumption patterns over the course of training, shown at different episodes. The shaded area represents business hours

夏季と冬季のそれぞれについて最終 Episode で得られた運用結果を、前節で提案した方法で成績に換算した。これらの成績を本選手権の結果のグラフに表すと Fig. 9 となる。エネルギー消費は夏季が 4.85 GJ、冬季が 0.92 GJ、平均不満足者率は夏季が 0.249、冬季が 0.265 となった。ECI_a は 0.202 となり、Eq. 9 を使ってパーセンタイル値を計算すると、下位 2.2%に相当する。本例は極簡単な強化学習手法だったためか、仮に WCCBO2 に参加したとしても成績は下位だっただろう。ともかく、このように、本研究で提案する方法により、強化学習による最適化の成績を公平に定量的に評価することができる。

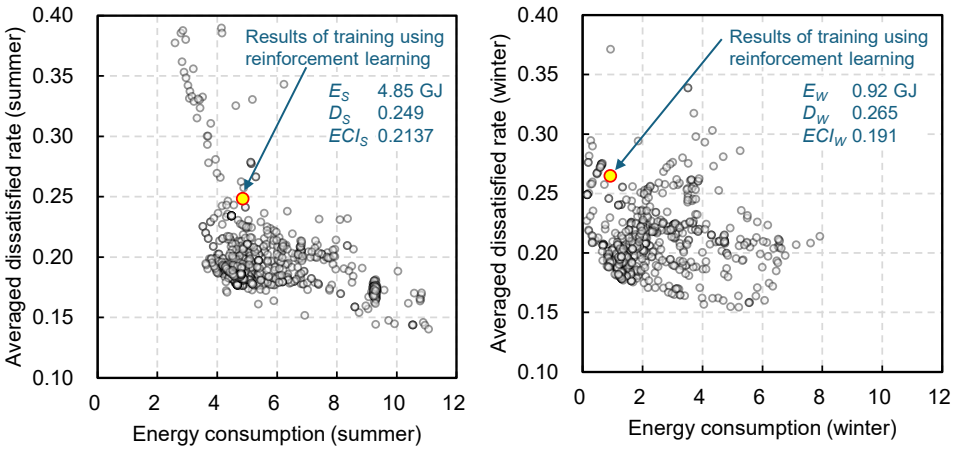


Fig. 9 Results of HVAC operation optimization using reinforcement learning

4. Discussion

本研究では、建物の最適化手法を定量的に評価する手法を提案した。しかし、開発した評価方法には 2 つの大きな課題が残る。第一の課題は、得られたデータの多くが過学習による最適化結果と予想されることである。第二の課題は、問題が仮想的な特定のケースに過ぎず、このままでは現実の建物に適用することができないことである。以下にそれぞれの課題の詳細と、解決方法の案を解説する。

4.1 Avoiding Overfitting

本研究では、選手権の開催期間を Preparation period と Evaluation period に分け、Evaluation period を 4 日間にすることで過学習を抑制しようとした。しかし、4 日間は長すぎ、多くのチームはこの期間に何度も再計算をして過学習に近い最適運用方法にたどり着いてしまった。この意味では、本選手権は未知の境界条件に対する制御の適応能力を競うものではなく、既知の境界条件を使った逆算能力を問うものとなったと言える。従って、得られたデータとその分布も、汎化性のある最適化手法の性能分布ではなく、過学習まで鍛えた最適化モデルの性能分布、に近い可能性がある。

この問題を解決する最も単純な方法は、成績評価のための計算を 1 回だけに限定するという方法だろう。しかし、本選手権のように競技者にエミュレータを配布してしまっては計算回数を限定することは難しい。解決方法としては、主催者が管理するサーバー側でエミュレータを走らせ、競技者はこれに遠隔で接続して制御値を操作するという仕組みが考えられる。サーバーに VPN 接続すれば BACnet 通信もできるため、現実の建物ではこのような設備管理は実現している。1st WCCBO では VPN 技術を使ったサーバーサイドのエミュレータのリアルタイム最適化という仕組みを用意したが、先に記したように、当時はそもそも BACnet 通信でエミュレータを操作する参加者が極少数だったため、この仕組みはあまり機能しなかった。しかし、3.4 節に記したように、本選手権ではかなりの数の参加者が BACnet 通信を使った制御を成功させているため、エミュレータの遠隔操作のための技術蓄積は進んでいると思われる。

ところで、3.4 節に記したように、極単純な強化学習では本選手権では好成績を納めることはできないと予想される。理想的には、過学習となっていない汎化性を獲得した強化学習モデルで好成績を納めるべきだが、まずはその前段階として、過学習でも良いからそもそも強化学習で第一位となる成績を取れるか否かは、上記の改善に先立って確認すべきだろう。

4.2 Integrating Emulator with Real Buildings

本研究で開発した評価式は、エミュレータでモデル化した建物や設備システムでしか使うことができない。従って、現実の特定の建物の最適化に応用するための仕組みが必要である。これはすなわち、エミュレータと現実の建物とを結びつける Real world coupling という問題である。以下で、エミュレータと競争原理を使い、現実の建物の設備運用最適化を実現するための一つの仕組みを提案する。

まず、現実の建物を用意してその建物のエミュレータを作るだけでは問題は解決しないという点には注意しなければならない。現実の建物を持たない本選手権では、エミュレータが建物の真実の挙動を表すとみなして競技を進めたが、よく知られるようにシミュレーションは現実と完全には一致しない（de Wilde et al. 2014）。この不一致は、その後のエミュレータを使った最適化という行為を無価値にする危険性を持っている。従って、エミュレータが現実を再現する精度の改善という点においても、何かしらの競争が働く自律的な改善の仕組みを用意すべきである。

このためにまず、設備運用の最適化という行為を、a. エミュレータを開発するという作業、b. エミュレータの出力を使って評価関数を定義するという作業、c. エミュレータと評価関数から構成される複合関数の逆問題を解いて最適制御パラメータを求めるという作業、の 3 つに分ける。この内、b はオーナーが担当すべき作業であり、a と c は競争原理を導入すべき作業である。このために a, b, c のそれぞれの作業を以下のように数式で表現する。

「a. エミュレータの開発」とは、次式において ε を最小化する関数 f_{emu} を推定するという作業である。

$$y_{obsv} = f_{emu}(x_{ctrl}, x_{unctrl}) + \varepsilon \qquad \text{Eq. 11}$$

ここで、y_{obsv} は観測できる出力であり、エネルギー消費量、室内の温湿度、執務者のクレームの数、などである。x_{ctrl} と x_{unctrl} はいずれも観測できる入力で、前者は制御できる入力（例えば空調機の制御値）、後者は制御できない入力（例えば気象条件や執務者行動）である。ε は、x_{ctrl} あるいは x_{unctrl} として観測できない入力が存在することに起因する誤差である。

このような入出力関係を同定する問題は競争に向いており（Athanasopoulos 2011）、例えば近年では主に機械学習の性能競争を目的とした kaggle（www.kaggle.com）という仕組みが知られている。建築分野でも古くから ASHRAE や SHASE で熱負荷あるいはエネルギー予測コンペティションが実施されており（Kreider et al. 1994; Haberl et al. 1996; SHASE 1998）、類似の方法で競争原理を導入することは容易だろう。

我々の選手権では、主に物理式にもとづいたエミュレータを使うことで f_{emu} を提供した。建築設備は熱的遅れが大きい複雑なシステムであるから、当面はこのような手法が主流であると予想される。一方で、近年の機械学習の発達の速度を鑑みると、将来的には純粋なデータドリブンで f_{emu} を同定できる可能性もあろう。実際、上記の ASHRAE や SHASE のコンペティションでは、同定対象の入出力関係が非常に単純であったことも原因となり、機械学習によるモデルが上位の成績をおさめている。

「b. 評価関数の定義」とは、以下のように観測できる出力 y_{obsv} を引数とする関数 f_{OOR} を定めるという作業である。

$$P = f_{OOR}(y_{obsv}) \qquad \text{Eq. 12}$$

ここで P は評価値であり、値が高いほど評価が高いとする。本選手権に即して言えば ECI_a が P である。本選手権では主催者が Eq. 1 から Eq. 3 で定義したが、どのような関数であっても良い。観測のしやすさという観点からすると、執務者たちの不満足感の申告値ではなく、単純に室温や相対湿度、あるいは PMV

値を使うような方法もあろう。また、快適性とエネルギー性能にどのような重みをつけるかも自由であるし、その他の何らかの観測可能な状態量を導入しても良い。重要な点は、現実の建物においては、オーナーがその権利と責任にもとづいて明確に評価関数を定義すべきという点である。評価対象とする基準が明確でなければ、責任の所在が不明確になり、性能改善も実現しない。従って、b という作業については競争原理を導入せずとも、オーナーが自身の利益を最大化しようと模索することで自ずと明確化されるはずである。コミッショニングにおける Owner's Project Requirements (OPR)に類推させれば、Owner's Operational Requirement (OOR)という概念を定義することができよう。

「c. 逆問題を解いて最適制御パラメータを求める」とは、次式に示すように、評価関数の出力を最大化させる制御内容 x^*_{ctrl} を求めるという作業である。

$$x^*_{ctrl} = arg\max_{x_{ctrl}} f_{OOR}\left(f_{emu}(x_{ctrl}, x_{unctrl})\right) \qquad \text{Eq. 13}$$

この制御内容 x^*_{ctrl} を求めるための関数を f_{ctrl} と定義する。本選手権では、エミュレータという形で関数 f_{emu} を提供し、Eq. 1 から Eq. 3 によって関数 f_{OOR} を定義し、競技者たちは f_{ctrl} をそれぞれに定義してこれらの情報にもとづいて Eq. 13 を解くことを競った。従って、逆問題を解くという作業については、本選手権によって競争原理の導入方法を提案できたと言って良いだろう。

以上のように 3 つの作業を分ければ、以下の手順を繰り返すことにより、運用は最適化される。ここで作業 a と作業 c を担当するサービサーをそれぞれサービサーA およびサービサーC と呼ぶ。

step 1: 第 n 期において、オーナーは n-1 期までに観測したデータセット（y_{obsv}, x_{ctrl}, x_{unctrl}）を提供する

step 2: サービサーA は n 期の f_{emu} を推定する

step 3: オーナーはサービサーA が提案した f_{emu} に n 期のデータを入力し、最良の成績を示したものを採用する。f_{emu} が採用されたサービサーは報酬を受け取る

step 4: オーナーはサービサーC に対して step 3 で採用した f_{emu} ならびに n+1 期用の評価関数を提供する

step 5: サービサーC は n+1 期の最適制御 x^*_{ctrl} を推定するための制御システム（f_{ctrl}）を提案する。

step 6: オーナーは提案された f_{ctrl} の中から評価値を最大にするものを n+1 期の最適制御システムとして採用する。制御システム f_{ctrl} が採用されたサービサーは報酬を受け取る

一旦、f_{emu} の推定という作業段階を定義することによって、step 4 においてサービサーC 達に共通の f_{emu} を提供することができ、この結果、step 6 で客観的な基準によって最良の制御を選択できる点に注意されたい。もしも a と c とを一式の作業として発注した場合には、サービサー達がそれぞれに独自の f_{emu} を定義するため、提案された最適制御を相互に比較して優劣を判断することができない。

上記のようなシステムが成立すれば、建築設備の入出力関係の同定と最適制御の提案という 2 つの作業に対して、より良いサービスを提供したものが報酬を受け取るようになる。従って、従来のようにビル管理者が固定的に雇われるのではなく、設備の運用というサービスが一般的な競争市場の中で扱われ、市場原理の中で技術が研ぎ澄まされる可能性が生まれる。

ただし、上記の議論はかなり抽象的で例えば以下のような論点もある。

・空調の非専門家である建物オーナーが自らの手で適切な f_{OOR} を定義し得るのか。

・サービサーを再評価するタイムステップの適切な間隔はいくらか。長すぎては競争が働きづらくなる一方で、短すぎては熱的に時間遅れがあるという建築設備の特性が評価されづらい。

・複数の主体の中で f_{emu} や f_{ctrl} を安全に、つまり知財を秘匿したままで受け渡す方法はあるのか。

これらの論点に答えを与えるためには、具体的な実践を伴った検討が必要だろう。次回以降の WCCBO では、現実世界（それが例えば小さな単室であったとしても）と対応したエミュレータを題材にすることが望ましい。

なお、この real world coupling の問題が解決された場合には、1）で挙げた過学習の防止という問題も同時に解決される。1 度しか生じない現実の将来予測が問題として提示できれば、過学習をしてしまったモデルは自然と淘汰されるためである。

5. Conclusion

本論文では、建築設備の最適化手法を定量的に評価するための 1 つの手法を提案した。このために VRF システムエミュレータを開発し、これを使った設備の運用選手権を開催し、その結果から最適化手法の評価式を導出した。また、強化学習などの先端的手法に対しても、提案枠組みが評価ツールとして適用可能であることを確認した点は、今後の AI 技術との融合に向けた技術基盤を提供するものである。一方で、選手権の構成に起因する過学習の懸念や、現実の建築物への応用（Real World Coupling）の難しさといった課題も明らかとなった。これらの課題に対しては、リモート制御環境や責任主体による評価関数定義、段階的な実建物フィードバックの導入などを通じて、解決の道筋を示した。なお、開発したツールとそのためのバックデータはすべて Web（https://www.wccbo.org）で公開済みである。

Nomenclature:

DR	: averaged total dissatisfied rate of occupant	[-]
E	: energy consumption	[GJ]
ECI	: energy saving and comfort index	[-]
$f_{ctrl}(\cdot)$	function representing the control strategy to determine control actions, x_{ctrl}	
$f_{emu}(\cdot)$	: function to simulate building equipment I/O	
$f_{OOR}(\cdot)$	: evaluation function	
N_{DR}	: Number of dissatisfied occupants	[persons]
N_{rank}	: number of teams that submitted valid scores for both summer and winter	[times]
P	: evaluation value (percentile)	[-]
x_{ctrl}	: observable and controllable inputs	[-]
x_{unctrl}	: observable but uncontrollable inputs	[-]
y_{obsv}	: observable outputs	[-]
σ_{BC}	: standard deviation of the data after the Box-Cox transformation	[-]
μ_{BC}	: mean value of the data after the Box-Cox transformation	[-]
$\Phi(\cdot)$	: Standard normal cumulative distribution function	

Subscript:

a	: annual	E	: energy consumption	w	: winter
DR	: dissatisfied rate	s	: summer		

References:

1) Al Mindeel, T., Spentzou, E., & Eftekhari, M. (2024). Energy, thermal comfort, and indoor air quality: Multi-objective optimization review. *Renewable and Sustainable Energy Reviews*, *202*, 114682. DOI: 10.1016/j.rser.2024.114682

2) Ala'raj, M., Radi, M., Abbod, M. F., Majdalawieh, M., & Parodi, M. (2022). Data-driven based HVAC optimisation approaches: A Systematic Literature Review. *Journal of Building Engineering*, *46*, 103678. DOI: 10.1016/j.jobe.2021.103678

3) Athanasopoulos, G., & Hyndman, R. J. (2011). The value of feedback in forecasting competitions. *International Journal of Forecasting*, *27*(3), 845-849. DOI: 10.1016/j.ijforecast.2011.03.002

4) Aynur, T., N. (2010): Variable Refrigerant Flow Systems: A Review, Energy and Buildings, 42 (7), pp. 1106–1112, DOI: doi.org/10.1016/j.enbuild.2010.01.024

5) Blum, D., Arroyo, J., Huang, S., Drgoňa, J., Jorissen, F., Walnum, H., T., Chen, Y., Benne, K., Vrabie, D., Wetter, M., and Helsen, L. (2021): Building optimization testing framework (BOPTEST) for simulation-based benchmarking of control strategies in buildings, Journal of Building Performance Simulation, 14:5, pp. 586-610, DOI: 10.1080/19401493.2021.1986574

6) Bushby, S. T., Castro, N., Galler, M. A., and Park, C. (2001): Using the Virtual Cybernetic Building Testbed and FDD Test Shell for FDD Tool Development, National Institute of Standard and Technology: NISTIR 6818

7) Bushby, S. T., Ferretti, N. M., Galler, M. A., and Park, C. (2010): The Virtual Cybernetic Building Testbed – A Building Emulator, ASHRAE Transactions, 116 (1): pp. 37–44

8) de Wilde, P. (2014). The gap between predicted and measured energy performance of buildings: A framework for investigation. *Automation in Construction*, *41*, 40-49. DOI: 10.1016/j.autcon.2014.02.009

9) Department of Energy (DOE). (2015): A Common Definition for Zero Energy Buildings. Washington, D.C.: U.S Department of Energy Office of Energy Efficiency and Renewable Energy. Accessed December 1, 2018.

http://energy.gov/sites/prod/files/2015/09/f26/bto_common_definition_zero_energy_buildings_093015.pdf.

10) Ding, Z., Fu, Q., Chen, J., Lu, Y., Wu, H., Fang, N., & Xing, B. (2023). MAQMC: Multi-Agent Deep Q-Network for Multi-Zone Residential HVAC Control [Article]. CMES - Computer Modeling in Engineering and Sciences, 136(3), 2759-2785. DOI: 10.32604/cmes.2023.026091

11) European Parliament, Council of the European Union. (2010): Directive 2010/31/EU of the European parliament and of the council of 19 May 2010 on the energy performance of buildings, Article 9 Nearly zero-energy buildings, Official Journal of the European Union

12) Haberl, J., and Thamilseran, S. 1996. "Predicting Hourly Building Energy Use: The Great Energy Predictor Shootout II: Measuring Retrofit Savings — Overview and Discussion of Results". *ASHRAE Transactions*. 102 (2) : 419–435

13) Huchuk, B., Sanner, S., & O'Brien, W. (2021). Development and evaluation of data-driven controls for residential smart thermostats [Article]. Energy and Buildings, 249, Article 111201. DOI: 10.1016/j.enbuild.2021.111201

14） International Energy Agency (IEA). (1997): Energy Conservation in Buildings and Community Systems Programme (ECBCS). Summary of IEA Annexes 16 and 17, Annex 17 – Building Energy Management Systems (BEMS) – Evaluation and Emulation Techniques

15） International Energy Agency (IEA). (1999): Energy Conservation in Buildings and Community Systems Programme (ECBCS). Annex 25 –Real Time Simulation of HVAC Systems for Building Optimization, Fault Detection and Diagnostics

16) International Energy Agency (IEA). 2023. The Breakthrough Agenda Report 2023, Accelerating transition across the world's most emitting sectors.

17) Kreider, J., F., and Haberl, J., S. 1994. "Predicting hourly building energy use: The great energy predictor shootout – overview and discussion of results". *ASHRAE Transactions.* 100 (2): 1104–1118

18） Lebrun, J. and Wang, S. W. (1993): Evaluation and Emulation of Building Energy Management Systems - Synthesis Report, IEA Annex 17 Final Report, University of Liege, Belgium

19） Lin, X., Lee, H., Hwang, Y., and Radermacher, R. (2015): A Review of Recent Development in Variable Refrigerant Flow Systems, Science and Technology for the Built Environment, 21 (7), pp. 917-933, DOI: 10.1080/23744731.2015.1071987

20) Ministry of Economy, Trade and Industry (METI). (2015): Definition of ZEB and future measures proposed by the ZEB Roadmap Examination Committee. Accessed December 1, 2018. http://www.enecho.meti.go.jp/category/saving_and_new/saving/zeb_report/pdf/report_160212_en.pdf

21) National Institute for Land and Infrastructure Management (NILIM). (2025): Investigation on building envelope design, equipment design and energy performance evaluation results of non-residential buildings - Analysis of input/output data of the energy performance calculation program for Japanese building energy code submitted in FY 2023 - (Technical Note No. 1318). National Institute for Land and Infrastructure Management. https://www.nilim.go.jp/lab/bcg/siryou/tnn/tnn1318pdf/ks1318.pdf

22) Society of Heating, Air-Conditioning and Sanitary Engineers of Japan (SHASE). 1998. "Research on fault diagnosis and optimization of heat storage HVAC system (in Japanese)". Final report of committee of heat storage optimization

23) Sun, G., Yu, Y., Yu, Q., Tan, X., Wu, L., Qin, R., & Wang, Y. (2024). Enhanced temperature regulation in compound heating systems: Leveraging guided policy search and model predictive control [Article]. Renewable Energy, 236, Article 121449. DOI: 10.1016/j.renene.2024.121449

24) Togashi, E., Kobayashi, T., Ogata, H., Hatada, H., Ayame, H., Edahiro, K., Satoh, M., Ukai, M., Momota, M., Miyata, M., Giannetti, N., Nagashima, S., Ueno, T., Katayama, T., Yamaguchi, Y., and Iio, Y. (2024): Development of a variable refrigerant flow system emulator to host the second World Championship in Cybernetic Building Optimization. *Journal of Building Performance Simulation*, *17*(4), 480-509. DOI: 10.1080/19401493.2024.2346528

25) Togashi, E., Miyata, M., & Yamamoto, Y. (2020). The first world championship in cybernetic building optimization. *Journal of Building Performance Simulation*, *13*(3), 391-408. DOI: 10.1080/19401493.2020.1741685

26）Vaezi-Nejad, H., Hutter, E., Haves, P., Dexter, A. L., Kelly, G., Nusgens, P., and Wang, S. W. (1991): Use of building emulators to evaluate the performance of building energy management systems, Proceedings of Building Simulation 1991 Conference. pp. 209–213

27) Xin, X., Zhang, Z., Zhou, Y., Liu, Y., Wang, D., & Nan, S. (2024). A comprehensive review of predictive control strategies in heating, ventilation, and air-conditioning (HVAC): Model-free VS model. *Journal of Building Engineering*, *94*, 110013. DOI: 10.1016/j.jobe.2024.110013

28）Zhang, G., Xiao, H., Zhang, P., Wang, B, Li, X., Shi, W., and Cao, Y. (2019): Review on Recent Developments of Variable Refrigerant Flow Systems since 2015, Energy and Buildings, 198, pp. 444-466, DOI: 10.1016/j.enbuild.2019.06.032

29）Zheng, W., Zabala, L., Febres, J., Blum, D., & Wang, Z. (2025). Quantifying and simulating the weather forecast uncertainty for advanced building control. Journal of Building Performance Simulation, 18(4), 530–545. https://doi.org/10.1080/19401493.2025.2453537

30) Zhou, S. L., Shah, A. A., Leung, P. K., Zhu, X., & Liao, Q. (2023). A comprehensive review of the applications of machine learning for HVAC. *DeCarbon*, *2*, 100023. DOI: 10.1016/j.decarb.2023.100023